



Universidade do Minho

APRENDIZAGEM PROFUNDA

David Teixeira PG55929

Eduardo Cunha PG55939


Nuno Rodrigues PG55966

Tiago Rodrigues PG56013



INTRODUÇÃO

- **Objetivo:** Distinguir textos gerados por IA de textos humanos, face à crescente sofisticação dos modelos de geração.
- Treino e comparação de diferentes modelos de Deep Learning.
- Avaliação do desempenho dos modelos.



CRIAÇÃO DO DATASET

- Recolha de dados de fontes públicas (artemgk/ai-text-detection-pile, NicolaiSivesind/human-vs-machine, ...)
 - Pré-processamento, incluindo padronização das labels ("human" = 0, "AI" = 1), tokenização e remoção de duplicados
 - Uso do CountVectorizer para converter textos em representações numéricas com 10.000 features
 - Divisão do dataset em treino (70%), validação (10%) e teste (20%)
 - Armazenamento dos dados processados em formato CSV
-

MODELOS RAIZ

Regressão Logística:

- Otimização com SciPy e Gradient Descent
- Regularização

DNNs:

- Funções de ativação (ReLU, Tanh, Sigmoid).
- Regularização (Dropout, L1/L2).
- Otimizadores (Adam, RMSProp).
- Diferentes Métricas (Accuracy e F1-score)
- Callbacks

RNNs:

- Problemas com dimensionalidade (1D vs. 3D).
- Embeddings adaptados (baixo desempenho).

MODELOS COM TENSORFLOW

DNNs:

- Melhoria com TF-IDF vs. tokenização simples (94% accuracy).
- Embeddings: GloVe (pré-treinado) vs. treino do zero.

RNNs:

- Comparação: SimpleRNN (dissipação) < GRU (eficiente) < LSTM (melhor desempenho).

Transformers:

- Alto custo computacional (1 hora e 20min/epoch).
- BERT: resultados modestos vs. complexidade.

ABORDAGENS COM LLMS

Zero/One-Shot Learning:

- Classificação por similaridade de embeddings (exemplo único).
- Bart, RoBERTa, DistilRoBERTa - Zero Shot
- Bert, RoBERTa, Bart - One Shot



Engenharia de Prompts:

- Few-shot com BERT e GPT (instabilidade nos resultados).


RAG:

- Não implementado (complexidade desnecessária para o problema).

1 SUBMISSÃO



2 SUBMISSÃO



RESULTADOS

1ª Submissão (Modelos Raiz):

- 2º lugar (73% accuracy).

2ª Submissão (Modelos Tensorflow)

- 5º lugar (67 e 69% accuracy).

3ª Submissão (Modelos Tensorflow)

- TBD

CONCLUSÃO

Desenvolvemos modelos próprios e baseados em bibliotecas consolidadas para distinguir entre textos escritos por humanos e gerados por inteligência artificial. Explorámos diferentes abordagens, implementámos soluções e analisámos os resultados obtidos.

Cumprimos os objetivos propostos, criando modelos robustos e eficazes para um problema atual e em constante investigação. No contexto da competição, os resultados foram bastante competitivos, refletindo a qualidade do estudo e da preparação.

Este trabalho também permitiu consolidar e aprofundar os conceitos estudados, aplicando-os na prática e explorando novas perspetivas sobre o tema.



Universidade do Minho

APRENDIZAGEM PROFUNDA

David Teixeira PG55929

Eduardo Cunha PG55939

Nuno Rodrigues PG55966

Tiago Rodrigues PG56013

